

CUDA-בּוּ CPU C++-בּ מינפּ יוהיז

CPU יבּ תיטימאה הקולחה, batch 500- batch 50, הדיחי הצרה: Hive לש ליעפה דוקל רצק ינכט קירדמ. הדדמנש הצאהו GPU-ל.

תחא השקב לש לעופב לולסמה



מאתום ONNX Runtime CUDA i-score kernel רד YuNet/SFace GPU: | הטלחו רושיי, YuNet חונעפ, הנכה, חונעפ CPU:

החיכום המגדה המ

תחא הנומת לע תותשרה תא הליעפּ CPU תסרג. מיסוחי מתואו תונומת נתוא לע YuNet + SFace תמישמ התוא תועצבמ תואסרגה יתש תצירטמ תבשחמ נכּמ רחאלו, מיירוקמ ONNX Runtime CUDA sessions לא תונומת B לש אלמ batch תחלוש CUDA תסרג. מעפ לכּ sfac_cuda.cu. רותמ מאתום kernel תועצמאב B x N ונימד

identity_cpu.exe מה מיליעפה בושיחה יכילהת. HTTP/Ursina רובע הרובעת תבכש ראשנ אוה. תשרה תא קירמ וניא Python **identity_cuda.exe**, ובבנש, מ-C++ מו-CUDA C++.

לעופב דבוע GPU נכיהו דבוע CPU נכיה

השוע דוקה המ	נקתה	בלש
image_io.cpp חנעפמ JPEG/PNG ל-RGBA.	CPU / C++	הנומת תניעט
prepare_detection_batch רוזנט רצוי NCHW BGR ו-padding.	CPU / C++	תנכה YuNet
dynamic batch B. רובע Or::Session שמתשמ CUDAExecutionProvider ב-	GPU תסרגב CUDA	YuNet inference
נויצ תודוקנ שמחו מינפ רחובו YuNet יטלפ 12 ארוק דוקה	CPU / C++	מיוהיז חונעפ
bilinear. המיגדו similarity transform בשחמ align_faces	CPU / C++	112 x 112 רושיי
batch. ה- לכל 128D לדוגב embedding רצוי ינשה Or::Session	GPU תסרגב CUDA	SFace inference
1. ררואל למרוגמ 128D רוטקו לכ	CPU / C++	לומרנ
מיוולת יתלב ונויצ יבושיח B x N רגשמ sface_cuda.cu	GPU / CUDA C++	Cosine scores
identity, runner-up, score, margin ו-accepted. מירחב	CPU / C++	JSON ו-פס

embeddings לש תינומה האוושהו YuNet/SFace מידבכה תשרה יפרג. GPU-ב צר בלש לכש נעוט וניא יחכונה דוקה: בושח CPU. לע ירוקמ C++ מיראשנ תיפוס הטלחהו רושיי, הנכה; מציאומ

500-1, רובע דוק ותוא

תועמשמ	לעופב הצרה	Batch
GPU-ה תא תאלממ הניא ויידע תויליבקמה; ילמינימ היהשה נמזו תונוכנ קדוב	CUDA provider רדר דיחי לולסמ	1
מינויצ N x 50 בשחמ kernel-ה זאו, תחא השקבב מיטירפ 50 מילבקמ YuNet/SFace	dynamic batch דיחי B=50	50
תויליפכ; תשרב מירבוע תומוקמה 500 לכ, 10 לופכ frames 50-ב מישמתשמ רשאכ תוגלודמ וניא	dynamic batch דיחי B=500	500

CUDA תויליבקמ שורפ המ

תויצולובנוק קרפמ ONNX Runtime. clock. ותואב תיזיפ תועצובמ תונומתה 500 לכש חטיבמ וניאו תודרפנ תוינכות 500 וניא Batch 500 ידממ-וד grid רגושמ מאתומה kernel-score ב. תונימז SM תודיחי יב threads יפלא קלחמ GPU-ה, CUDA kernels-ל הצירטמ תולועפו ויקת thread לכל דחא score מע, מיוסוחיי לש מיקולב $\text{ceil}(N/256)$ לופכ התליאש תורוש B

B קיידב ריזחמ worker-ה, מיביתנ B רצוי benchmark_native.ps1. תומישמ רשע תראשנ מימעפ רשע הנומת התוא לע הרזח מימאות מניא expected identity וא count מא תלשכנ הקידברה, תואצות

תזכרם תודוקפו מיליעפ מיצבק

קיודמ דיקפת	הדוקפ	צבוק
YuNet ו-SFace לש sessions-ל CUDAExecutionProvider רבחמ	options.AppendExecutionProvider_CUDA	sface_engine.cpp
אלמ dynamic batch רובע ONNX יפרג ינש תא צירמ	yunet.Run(...) / sface.Run(...)	sface_engine.cpp
האירק לכל דחא frame-CPU: ב יתרדס baseline הנוכב רצוי	for (...) embed_images({images[index]})	sface_engine.cpp
לדוגב Bx128 ו-references לדוגב queries הלעמו וקתה ירגאמ הצקמ Nx128.	cudaMalloc / cudaMemcpy H2D	sface_cuda.cu
block=256, grid=(ceil(N/256), B), מאתומו kernel רגשמ	cosine_scores_kernel<<<grid, block>>>	sface_cuda.cu
thread query/reference גוזל multiply-add תולועפ 128 עצבמ דיחי	dot += query[d] * reference[d]	sface_cuda.cu
GPU-ה ירגאמ תשולש לכ תא ררחשמו BxN ינויצ ריזחמ	cudaMemcpy D2H / cudaFree	sface_cuda.cu
Hive. תושקב יוב מינועט סוחיי לש embeddings-ו מילדומו ריאשמ	--serve-tsv	sface_identity_cli.cpp

הז בשחמב תתמואמ האוושה

כלל מדקומו מומיחו, מיסוחיי תונומת, מילדומו מתוא, מיירוקמ Release יצבוק. Intel Core i9-14900K + NVIDIA GeForce RTX 4060. batch תרוצ

תונוכ	הצאה	C++/CUDA batch	יתרדס CPU C++	סמוע
50/50	2.31x	2840.1 ms	6551.4 ms	50
500/500	6.97x	9365.7 ms	65304.2 ms	500

identity_cpu.exe ל קר תסחיימת הלבטה. ורסוה מדוקה PDF-ה Python/PyTorch לש מינשיה מירפסמה. תוינש 9.37-כל 65.3-כמ נמזה תא הניטקמ CUDA batch 500 ב. מייחכונה identity_cuda.exe לו

batch מע לדג נורתיה עודמ

רביסה	פרוג
תמדוקה ירחא הליחתמ האבה היצריטיאה; i-SFace רושיי, YuNet ןרד דרפנב רבוע frame לכ	CPU baseline
תנומת רתוי ןיב תקלחתמ i-runtime kernels רוגיש תולעו, GPU-ה תא רתוי בוט אלממ לודג רוזנט	CUDA batch
ןיקת גוז לכל דרפנ thread הצקמ CUDA; םייולת יתלב תוגוזה B x N לכ	Score kernel
הדיחי הנומתל רתוי ריהמ תויהל בייח וניא GPU; חוורה תא םיתיחפמ ןטק batch-i חראמה דצב רושיי, ןורכיז תורבעה	הלבגמ

רזחשל דציכ

1	Release: .\setup_windows.ps1 -CudnnBin PATH_TO_CUDNN_BIN תיינב
2	identity_cpu.exe, identity_cuda.exe, ONNX Runtime CUDA DLL, CUDA runtime i-cuDNN 9. םימייקש אדוויל שי
3	RuntimePaths PATH_TO_CUDNN_BIN -benchmark_native.ps1. ןחבמ ותוא תצרה
4	batch, correct, errors, recognition_ms i-images_per_second. קודבלו results/native_face_cpu_cuda_results.csv חותפל שי
5	inference ב-Python. עצבמ וניאו ךשמתמו ירוקמ worker ליעפמ server.py; AI_MIPS_NATIVE_FACE=1; ריאשהל שי Hive רובע

טקיורפה תנגהל םוכיס

לע תססובמ הניא האצותה. המישמ התוא רובע batch ב-CUDA/C++ לומ יתרדס CPU C++ :תרכובמ האוושה גיצמ טקיורפה תיזכרמה הביסה. םייוהיז 500 רובע א6.97-ו 50 רובע א2.31 איה הצאהה RTX 4060-ב. תובושת לש cache לע וא תויוליפכ גוליד cosine. ינויצ B x N לש יולת יתלב יליבקמ בושיחו CUDA לע batch ב-YuNet/SFace תצרה איה